

データサイエンス基礎I

第12回 FDSでの積分の使いみち = 確率の計算
+ 期末試験に向けて


担当：田村龍一

復習：積分の考え方と計算方法

考え方 + 微分積分学の基本定理(2つ) → 定積分の計算方法

● 積分の考え方(定積分の定義)

- ▶ 曲線で囲まれた面積を求めることが目標
- ▶ 幅の微小な長方形の面積の総和を、定積分と定義する。



● 定積分 $\int_a^b f(x)dx$ を計算する方法

- ▶ 原始関数 $F(x)$ を見つける： $F'(x) = f(x)$
- ▶ 積分範囲の上端 b ・下端 a の値を使うと曲線で囲まれた面積は $F(b) - F(a)$ で求まる。

$$\int_1^2 x^2 dx$$

$$F(x) = \frac{1}{3}x^3 \left(F'(x) = 3 \times \frac{1}{3}x^{3-1} = x^2 \equiv f(x) \right)$$

$$\begin{aligned} \int_1^2 x^2 dx &= F(2) - F(1) = \left(\frac{1}{3}2^3 \right) - \left(\frac{1}{3}1^3 \right) \\ &= \frac{8}{3} - \frac{1}{3} = \frac{7}{3} \end{aligned}$$

FDS授業/演習で、積分はいつ使われるか？

分析系FDS授業の
典型的学習パターン

- ① 食と農の現実から、データを得る
↓
- ② データを**数理モデル**で表す
↓
- ③ **数理モデル**から**確率**を計算する
↓
- ④ **確率**を、分析と予測に利用する

確率の計算 ≡ 積分の計算

この授業では、みなさんがよく知っている現実例 = **身長**を事例として、**確率の計算に積分をどう使っていくか**を説明する。

STEP 1: データの比率から確率へ

DSで現実データを表すときに頻繁に使われる「比率」

「比率」は、「確率」として考えるのがDS流のデータの読み方。


令和7年度 17歳男子高校生の身長データ

データ

min

身長	比率
143cm	0.0001
144cm	0
145cm	0
146cm	0
147cm	0
148cm	0.0001
149cm	0.0003
⋮	⋮
167cm	0.0548
168cm	0.0588
169cm	0.0661
170cm	0.0713
171cm	0.0704
172cm	0.0666
⋮	⋮
190cm	0.0002
191cm	0.0002
192cm	0.0001
193cm	0.0001
194cm	0.0002
195cm	0.0001

max




- 厚生労働省「学校保健統計調査」
- 身長は、1cm刻みで記録されている。
 - ▶ "階級幅" = 1cm
- それぞれの身長に含まれる男子高校生の比率が記載されている。
 - ▶ 17歳男子高校生の総数はおよそ100万人
- 読み方：[身長 = 170cm]の比率は0.0713 → 人数は、総数に比率を掛けた値(7万1300人)

比率データの理解のしかた(1)

特定の身長をもつ男子高校生の比率は？

身長	比率
143cm	0.0001
144cm	0
145cm	0
146cm	0
147cm	0
148cm	0.0001
149cm	0.0003
：	：
167cm	0.0548
168cm	0.0588
169cm	0.0661
170cm	0.0713
171cm	0.0704
172cm	0.0666
：	：
190cm	0.0002
191cm	0.0002
192cm	0.0001
193cm	0.0001
194cm	0.0002
195cm	0.0001



① 身長の比率の値は、必ず
0以上、1以下

問題：身長が、170cmまたは171cmの男子の比率は？

② 身長の比率の値は、それぞれの比率の和, または
棒グラフの高さの和で求められる。

比率データの理解のしかた(2)

③ 比率の総和は、1

Excelを使って、
身長の
最小値142cmから
最大値195cmの
総和をSUM関数で計算


45	186cm	0.003
46	187cm	0.0012
47	188cm	0.0015
48	189cm	0.0008
49	190cm	0.0002
50	191cm	0.0002
51	192cm	0.0001
52	193cm	0.0001
53	194cm	0.0002
54	195cm	0.0001
55		=SUM(B2:B54)
56		

45	186cm	0.003
46	187cm	0.0012
47	188cm	0.0015
48	189cm	0.0008
49	190cm	0.0002
50	191cm	0.0002
51	192cm	0.0001
52	193cm	0.0001
53	194cm	0.0002
54	195cm	0.0001
55		1.0

全ての身長の
比率を総和すると

1 になる。

③ 棒の高さの総和は、1



比率を「確率」として考える

- ① 身長 of 比率の値は、必ず0以上、1以下
- ② 身長 of 比率の値は、それぞれの**比率の和**、または棒グラフの高さの和で求められる。
- ③ 比率の総和 = 棒の高さの総和、**1**

- 身長 of 値を142cmから1cm刻みで195cmまで設定すると、17歳男子高校生全員の身長 of 取りえる値全てをカバーできる。
- 各身長をもつ比率は、①②で知ることができる。
- 全ての身長 of 値 of 比率 of 合計は、③から、必ず「1」。
- このような条件が満たされるとき、比率 of 値は、「17歳男子高校生が、ある身長となる確率」として考えることができる。

確率の記号 P を導入する

身長を、大文字の**変数** X で表す。具体的な**身長**の値を、**数字または小文字** x で表す

変数 X の取りえる値の範囲は、 $X = 142, 143, \dots, 194, 195$

身長が具体的な値(x_1)のときの確率(比率)を、次のように表記する：

数式の書き方：

$$P(X = x_1) = p_1$$

数式の読み方：

"身長の変数 X の値が x_1 である確率は、 p_1 である"

例： "身長の変数 X の値が 171cm である確率は、0.0704である"

$$P(X = 171) = 0.0704$$

練習問題

グラフの読み取りから得た情報を、確率記号 P を使って表現しよう

17歳高校生男子の身長を表す変数を X とする。

(1) 身長が170cmである確率は、0.0713である

(2) 身長が171cmである確率は、0.0704である。よって、身長が170cmまたは171cmである確率は、0.1417である。

とり得る値と、出現確率がペアになった変数＝確率変数

X

身長	比率
143cm	0.0001
144cm	0
145cm	0
146cm	0
147cm	0
148cm	0.0001
149cm	0.0003
: : :	
167cm	0.0548
168cm	0.0588
169cm	0.0661
170cm	0.0713
171cm	0.0704
172cm	0.0666
: : :	
190cm	0.0002
191cm	0.0002
192cm	0.0001
193cm	0.0001
194cm	0.0002
195cm	0.0001

x の値


$P(X = x)$

- 17歳男子高校生の身長を表す変数 X は、左表のように「とり得る値と、その値が起こる確率」がペアになっている。
 - ▶ とり得る値：143～195 (1cm刻み)
 - ▶ 比率＝確率：0以上1以下の値
- このような**確率の情報が追加された変数**を、**確率変数**と呼ぶ。
 - ▶ データサイエンスの世界では、変数の値と、それに紐づいた確率が左のような一覧表で与えられることが多い。


— 17歳男子高校生の身長を表す**確率変数 X** の性質 —

$$0 \leq P(X = x) \leq 1 \quad \sum_{x=143}^{195} P(X = x) = 1$$

確率変数は、「関数」と同じ「入力→出力」構造を持つ



関数：入力 $x = 1$ から、出力 $f(1)$ を得る





確率変数：入力 $X = 170$ から、出力 $P(X = 170)$ を得る

- 確率変数は、 X のとり得る値それぞれに確率が与えられている。
- よって、 X の特定の値を入力、確率を出力と解釈すれば、これまで学んできた関数と同様の「入力から出力を得る」という構造をもつことが分かる。

確率の「数理モデル化」


私たちが今後取り扱うデータの内容は、経済学や統計学の理論を根拠とした数理モデル(数式)でうまく近似できることが多い。

身長を「モデル化」する




- データサイエンスでは、現実のデータをそのまま扱うだけではなく数式(モデル)で近似して解析する。
- 身長は、**正規分布(Normal Distribution)**という滑らかな曲線=数式(モデル)で精度良く近似できることが知られている。

モデルから確率を計算する



ズームアップ

身長が170cm以上172cm未満になる確率




棒グラフなら、170cmと171cmの棒の高さを足し合わせれば、比率を計算できた。


曲線のモデルでは、170cm代から171cm代までの割合をどう求めればよいだろうか？

⇒ 「積分の考え方」を、ここで適用する！

考え方：幅の狭い長方形を敷き詰めて、比率を近似する




曲線には、棒グラフのような明確な棒がない。
そこで、170cmから172cmまでの範囲を細かい区間に
分けて、各区間を小さな長方形で敷き詰めていく。



➡ $[x, x + \Delta x]$ という身長の間には、全体の $f(x) \times \Delta x$
の比率(確率)だけ、高校生が存在する。

➡ 1つの長方形で近似した小区間の比率(確率) $f(x_i)\Delta x$

確率密度関数




- 線の高さ $f(x)$ 自体は確率ではない。
- 高さに区間の幅を掛けた**長方形の面積が、その小区間の確率(比率)になるように、高さを定めている。**
- **この高さを確率密度と呼び**、関数 $f(x)$ を確率密度関数と呼ぶ。

$$\text{面積(確率)} = \text{高さ}f(x) \times \text{幅}\Delta x \iff \text{高さ}f(x) = \frac{\text{面積(確率)}}{\text{幅}\Delta x}$$


幅1cmあたり、男子高校生の比率(確率)はどれだけか？
→ **高さ $f(x)$ は、幅1cmあたりの比率(確率)の密度と解釈**する。

「積分の考え方」を適用



$$\lim_{n \rightarrow \infty, \Delta x \rightarrow 0} \sum_{i=1}^n f(x_i) \Delta x =$$

幅をどんどん狭くしていった
ときの長方形の面積の総和





$$\int_{170}^{172} f(x) dx$$

身長が170cm以上172cm未満の
男子高校生の比率(確率)

確率密度関数の特徴

棒グラフと同様の特徴をもっている



① 身長の比率の値は、**必ず0以上、1以下**


確率密度関数の出力は、常に0以上

③ **棒の高さの総和**は、**1**

とり得る**範囲全体の面積**は、**1**

なお、ここで扱っている正規分布の確率密度関数の定義域は、実数全体($-\infty, +\infty$)であると定義されている。

面積計算に関するポイント




平均身長が170.6cm、身長の標準偏差が5.99cm
のときの、正規分布の確率密度関数 $f(x)$

$$f(x) = \frac{1}{\sqrt{2\pi} \times 5.99} e^{-\frac{(x-170.6)^2}{5.99^2}}$$

計算したい面積 = $\int_{170}^{172} f(x) dx$

- 正規分布の確率密度関数 $f(x)$ は、ものすごい複雑な形
 - ▶ 原始関数 $F(x)$ を見つけることは、至難の業。統計分析ではこんなケースがとても多い。
- 解決策：パソコンとの共同作業
 - ▶ Excel、R、Pythonといったアプリには、確率を計算する関数が備わっている。
 - ▶ 私たち人間が担当するタスク：**計算の手順を理解し、正しい値を計算できるようにアプリに指示する。**

アプリとの共同作業を実現するために導入する概念：累積分布関数



$f(x)$ は、**確率密度関数**と総称される。


この例では、「正規分布の確率密度関数」と表記する。

確率密度関数の定義域

$$-\infty < x < +\infty \text{ (どんな値でもOK)}$$

確率密度関数の値域

$$f(x) > 0 \text{ (正の値)}$$



$F(x) = \int_{-\infty}^x f(t)dt$ は、**累積分布関数**と総称される。


この例では、「正規分布の累積分布関数」と表記する。

確率密度関数の $-\infty$ から x までの領域の面積を求める関数。

重要ポイント：確率密度関数の原始関数である。

$$F'(x) = f(x)$$

アプリの計算機能を活用する方法



	A
1	=NORM.DIST(170, 170.6, 5.99, TRUE)
2	0.460105894

Excelには、累積分布関数 $F(x)$ の値を直接計算してくれる **NORM.DIST** という関数がある。

平均170.6、標準偏差5.99の正規分布で、 $P(X \leq 170) = F(170)$ となる確率を上セルのように入力して求めることができる。

- Excel, R, Python, ExploratoryといったFDSで活用するアプリには、正規分布に関して確率変数が、**特定の値 c 以下となる確率 $P(X \leq c) = F(c)$ を直接計算**してくれる機能が搭載されている。
 - ▶ どのアプリも「 **c 以下となる確率**」 $P(X \leq c) = F(c)$ の計算しか提供してくれないことに注意。
- 私たち(人間)は、それ以外のケースの確率を計算する際に、 $P(X \leq c) = F(c)$ を活用していく方法を学ぶ必要がある。



確率の計算

データサイエンスでは、**アプリが計算する基本的な確率**を組み合わせ、不等号で表されるさまざまな範囲の確率を計算することがほとんどである。

そのために基本形(①)を抑え、①を使った応用計算公式②～④を身につけよう。


- ① 以下の確率 $P(X \leq a)$
- ② 以上の確率 $P(X \geq a)$
- ③ 範囲の確率 $P(a \leq X \leq b)$
- ④ 範囲外の確率 $P(X \leq a \text{ または } X \geq b)$

基本：「以下」の確率



- Excel, R, Python, Exploratoryが計算してくれるのは、「以下」の確率である。
 - ▶ $-\infty$ から a, b までの領域の面積（定積分）： $P(X \leq a)$ や $P(X \leq b)$ を算出してくれる。
- この「以下」の確率を基本として、3つのタイプの確率を計算する方法を学ぶ。

「以上」の確率




$$P(X \geq b) = 1 - P(X \leq b)$$

以上の確率は 1から 以下の確率を引く


範囲の確率

$$P(a \leq X \leq b)$$




=

$$P(X \leq b)$$



-

$$P(X \leq a)$$




$$P(a \leq X \leq b) = P(X \leq b) - P(X \leq a)$$

範囲の確率は

上端以下の確率から 下端以下の確率を引く

範囲外の確率

$P(X \leq a, \text{ または } X \geq b)$




1



—

$P(a \leq X \leq b)$



$$P(X \leq a, \text{ または } X \geq b) = 1 - P(a \leq X \leq b)$$

範囲外の確率は

1から

範囲の確率を引く

$$= 1 - (P(X \leq b) - P(X \leq a))$$


計算公式から分かること：1点の確率 $P(X = a)$ は、ゼロである

$P(X = a)$ を、(あえて)不等号を使って表すと $P(a \leq X \leq a)$ と表記できる。
これは「**範囲**」の確率である。

範囲の確率の計算公式を適用すると：

$$P(X = a) = P(a \leq X \leq a)$$

$$= P(X \leq a) - P(X \leq a) \equiv 0$$



直感に反する理由：本当の身長と、測定値の違い

身長がちょうど170cmと測定された人でも、身長測定器には「精度の限界」があるので、本当の身長は、169.98cmや170.01cmなど様々である。

ちょうど170cmの範囲には幅がないため、面積は0、したがって確率も0になる。


計算公式から分かること：1点の確率 $P(X = a)$ は、ゼロである

$P(X = a)$ を、(あえて)不等号を使って表すと $P(a \leq X \leq a)$ と表記できる。
これは「**範囲**」の確率である。

範囲の確率の計算公式を適用すると：

$$P(X = a) = P(a \leq X \leq a)$$

$$= P(X \leq a) - P(X \leq a) \equiv 0$$




直感に反する理由：本当の身長と、測定値の違い

身長がちょうど170cmと測定された人でも、身長測定器には「精度の限界」があるので、本当の身長は、169.98cmや170.01cmなど様々である。

ちょうど170cmの範囲には幅がないため、面積は0、したがって確率も0になる。

注意：棒グラフとの関係性



棒グラフでは、身長を表す確率変数 X が特定の値のときの確率を表すことが可能だった。

例： $P(X = 170) = 0.0713$ 、 $P(X = 171) = 0.0704$

近似する正規分布の確率密度関数 $f(x)$ を使った確率計算では、前スライドから、 $P(X = 170) = 0$ 、 $P(X = 171) = 0$ 。

なんでちがうの??

棒グラフ（データを要約/可視化したもの）→ 学校保健調査では、身長の計測値を、1cm刻みの人数で集計している。

$P(X = 170) = 0.0713$ とは、実際は範囲の確率： $P(170 \leq X < 171) = 0.0713$ である。

$P(X = 171) = 0.0704$ とは、実際は範囲の確率： $P(171 \leq X < 172) = 0.0704$ である。

確率密度関数 $f(x)$ は、元データの情報から身長を数理モデル化したもの。人間の(生物学的)身長はとびとびの値ではなく連続的に変わる量と捉えている。

練習問題

確率計算問題の典型的な出題文と、その解き方を身につけよう

17歳高校生男子の身長は、近似的に平均170.6cm、標準偏差5.99cmの正規分布に従うことが知られている。このとき、次の問いに答えなさい。

- (1)身長が160cm以下は全体の15%、身長が165cm以下の人は全体の27%いる。身長が160cm以上、165cm以下の人は、全体の何%であるか。
- (2)身長が185cm以下の人は全体の94%いる。身長が185cm以上の人は全体の何%であるか。

(解)

身長を表す確率変数を X とすると、 $P(X \leq 160) = 0.15$ 、 $P(X \leq 165) = 0.27$ 、 $P(X \leq 185) = 0.94$ である。

(1)

(2)

今日のポイント

面積計算での呼び名：

関数 $f(x)$

原始関数 $F(x)$

確率計算での専用の呼び名：

確率密度関数 $f(x)$

累積分布関数 $F(x)$

$$f(x) \geq 0, \int_{-\infty}^{\infty} f(x) = 1$$

$$F(x) = \int_{-\infty}^a f(x) dx$$

面積は、原始関数 $F(x)$ の引き算で計算できた。

確率も、累積分布関数 $F(x)$ の引き算で**計算**できる。

(3つの計算公式)